

Tarea 2: Física computacional

Estudiante: Benjamín Medina S.¹, benjamin.medinas@usm.cl
Ayudante: Cristobal Benavides ¹, cristobal.benavidesv@usm.cl
Profesores: Ariel Norambuena Z.¹, ariel.norambuena@usm.cl
Nicolas Viaux M.¹, nicolas.viaux@usm.cl

¹*Departamento de Física, Universidad Técnica Federico Santa María, San Joaquín, Chile*

1. Problema 1: Inteligencia Artificial para Problemas Inversos

(a) Conceptos teóricos

Problema directo e inverso. En el **problema directo** se conocen los parámetros físicos (γ, k) y se calcula la señal $x(t)$ resolviendo la ecuación diferencial

$$\ddot{x}(t) + \gamma \dot{x}(t) + k x(t) = 0, \quad x(0) = 1, \dot{x}(0) = 0.$$

Este problema tiene *solución única y estable*: dados los parámetros, la solución analítica del oscilador subamortiguado es

$$x(t) = e^{-\frac{\gamma}{2}t} \left[\cos(\omega_d t) + \frac{\gamma}{2\omega_d} \sin(\omega_d t) \right], \quad \omega_d = \sqrt{k - \frac{\gamma^2}{4}}.$$

El **problema inverso** consiste en lo opuesto: a partir de la señal medida $x(t)$ (posiblemente con ruido) recuperar (γ, k) . La dificultad principal es que el problema inverso suele estar *mal condicionado (ill-posed)*: pequeñas perturbaciones en la señal (ruido experimental) pueden producir grandes variaciones en los parámetros estimados, y distintas combinaciones de parámetros pueden generar señales muy parecidas (no unicidad práctica). Además no existe, en general, una fórmula explícita que invierta $x(t) \rightarrow (\gamma, k)$.

Aprendizaje supervisado. Disponemos de un conjunto de datos etiquetados $\{(\mathbf{x}_i, \theta_i)\}_{i=1}^N$, donde $\mathbf{x}_i$ es la señal observada y $\theta_i = (\gamma_i, k_i)$ son las *etiquetas* correcta). El modelo aprende una función $f_\phi : \mathbf{x} \mapsto \hat{\theta}$ ajustando sus parámetros internos ϕ para minimizar el error entre $\hat{\theta}$ y θ . **Sí es necesario conocer las etiquetas** durante el entrenamiento: el problema inverso se resuelve precisamente porque generamos los datos sintéticamente con el problema directo (sabemos qué (γ, k) produjo cada señal). Sin etiquetas tendríamos un problema no supervisado, que no permitiría inferir los parámetros físicos directamente.

Conjuntos de entrenamiento y validación. Los datos se separan en **train** (80%) y **test** (20%) para evaluar la capacidad de *generalización* del modelo. El conjunto de entrenamiento se usa para ajustar los parámetros; el de validación, nunca visto durante el entrenamiento, mide el desempeño en datos nuevos. Si solo midiéramos el error en el conjunto de entrenamiento podríamos sobrestimar la calidad del modelo (sobreajuste).

Función de pérdida. Se define un error que el modelo busca minimizar. El error cuadrático medio

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N \left[(\gamma_i - \hat{\gamma}_i)^2 + (k_i - \hat{k}_i)^2 \right]$$

penaliza fuertemente los errores grandes (por el cuadrado), es diferenciable (útil para optimización por gradiente) y proporciona una medida escalar única que cuantifica qué tan bien el modelo resuelve el problema inverso. Su minimización equivale a la estimación de máxima verosimilitud bajo ruido gaussiano.

(b) Generación del dataset

Se generaron $N = 3000$ señales resolviendo numéricamente la EDO (método RK45) en $t \in [0, 10]$ con $N_t = 1000$ puntos, escogiendo $\gamma \sim \mathcal{U}(0,05, 1,0)$ y $k \sim \mathcal{U}(1,0, 5,0)$, y agregando ruido gaussiano $\eta_j \sim \mathcal{N}(0, \sigma^2)$ con $\sigma = 0,02$.




Figura 1: Efecto de los parámetros sobre la señal. **Izquierda:** al aumentar γ la amplitud decae más rápido (mayor amortiguamiento). **Derecha:** al aumentar k aumenta la frecuencia de oscilación ($\omega_d \approx \sqrt{k}$).




Figura 2: Ejemplo de señal con ruido gaussiano comparada con la señal limpia.

Discusión: La *frecuencia* de oscilación está controlada principalmente por k (rigidez): mayor $k \Rightarrow$ oscilaciones más rápidas. El *decaimiento* de la amplitud está controlado por γ : mayor $\gamma \Rightarrow$ la envolvente $e^{-\gamma t/2}$ decae antes.

(c) Entrenamiento de los modelos

Se entrenaron un `RandomForestRegressor` y un `MLPRegressor` con división 80/20.

Modelo	RMSE $_{\gamma}$	RMSE $_k$
Random Forest	0.0156	0.1041
MLP	0.0218	0.0312

Tabla 1: RMSE de cada modelo en el conjunto de validación.




Figura 3: Valores predichos vs reales. Los puntos sobre la diagonal roja indican predicciones perfectas.

(d) Efecto del ruido




Figura 4: RMSE de γ y k en función de la amplitud del ruido σ .




Figura 5: Comparación del error de entrenamiento y de validación. La brecha entre ambas curvas es una manifestación del **sobreajuste**.

Discusión: El parámetro γ (amortiguamiento) suele ser más difícil de inferir que k , pues afecta sutilmente la envolvente de la señal mientras que k determina directamente la frecuencia (fácilmente identificable incluso con ruido). A medida que σ aumenta, ambos RMSE crecen. El **sobreajuste** se manifiesta cuando el error de entrenamiento es pequeño (el modelo memoriza el ruido) pero el error de validación es grande: el modelo no generaliza a datos nuevos.

2. Problema 2: Terapia con Protones

(a) Conceptos teóricos

Pico de Bragg. La dosis depositada $D(z)$ por un haz de protones presenta un máximo muy localizado al final del recorrido. Esto ocurre porque el poder de frenado $-dE/dx \propto 1/\beta^2$ crece dramáticamente cuando

el protón se frena ($\beta \rightarrow 0$): la mayor parte de la energía se deposita en los últimos milímetros antes de detenerse. La curva muestra una región de entrada de dosis baja, un pico agudo, y una caída abrupta a cero detrás del pico (los protones se han detenido).

Ecuación de Bethe–Bloch.

$$-\frac{dE}{dx} = Kz^2 \frac{Z}{A} \frac{1}{\beta^2} \left[\frac{1}{2} \ln \frac{2m_e c^2 \beta^2 \gamma^2 T_{\text{máx}}}{I^2} - \beta^2 \right]$$

donde:

- $K = 0,307 \text{ MeV} \cdot \text{cm}^2/\text{g}$: constante universal.
- $z = 1$: carga del protón (en unidades de e).
- $Z/A = 0,5551$: relación carga/masa del agua.
- $\beta = v/c$, $\gamma = 1/\sqrt{1 - \beta^2}$: variables cinemáticas.
- $m_e c^2 = 0,511 \text{ MeV}$: energía en reposo del electrón.
- $T_{\text{máx}}$: máxima energía transferible a un electrón en una colisión.
- $I \approx 75 \text{ eV}$: potencial medio de excitación del agua.

El factor z^2 proviene de que la fuerza de Coulomb es proporcional a la carga del proyectil, y la energía transferida al cuadrado de ésta. El factor $1/\beta^2$ refleja que partículas lentas pasan más tiempo cerca de cada electrón, transfiriéndole más energía: es el origen físico del pico de Bragg.

Energy straggling. La pérdida de energía es estadística: cada colisión transfiere una cantidad aleatoria de energía. En la aproximación gaussiana de Bohr, la varianza es

$$\sigma_E^2 = 4\pi r_e^2 (m_e c^2)^2 N_e \frac{z^2}{\beta^2} \Delta x,$$

donde N_e es la densidad electrónica del medio. Esto hace que protones idénticos se detengan a profundidades ligeramente distintas, ensanchando el pico de Bragg.

Dispersión Coulombiana múltiple. Las colisiones con los núcleos desvían angularmente al protón. En la aproximación de Highland,

$$\theta_0 = \frac{13,6 \text{ MeV}}{\beta c p} z \sqrt{\frac{\Delta x}{X_0}} [1 + 0,038 \ln(\Delta x/X_0)],$$

donde X_0 es la longitud de radiación del medio. Produce un ensanchamiento lateral del haz.

(b) Bethe–Bloch y rango CSDA




Figura 6: Poder de frenado de Bethe–Bloch para protones en agua.

El rango CSDA se calcula integrando

$$R_{\text{CSDA}}(E_0) = \int_0^{E_0} \frac{dE}{(-dE/dx)(E)}.$$

E_0 (MeV)	R_{sim} (cm)	R_{NIST} (cm)	Error (%)
50	2.221	2.227	0.26
150	15.766	15.77	0.02
250	37.930	37.94	0.03

Tabla 2: Comparación del rango CSDA simulado con valores tabulados de NIST PSTAR.

(c) Simulación sin fluctuación

Se simularon $N = 10^4$ protones de $E_0 = 150$ MeV con $\Delta x = 0,1$ mm, restando $\Delta E = (-dE/dx)\Delta x$ en cada paso.




Figura 7: Dosis depositada $D(z)$ (sin straggling). El pico de Bragg coincide con el rango CSDA calculado en (b).

(d) Simulación con straggling




Figura 8: Comparación del pico de Bragg con y sin straggling. La fluctuación estadística ensancha y reduce ligeramente la altura del pico.




Figura 9: Distribución de los rangos de detención debido al straggling. El ancho de la distribución es σ_R .

Relevancia clínica: El ensanchamiento σ_R del pico (del orden de $\sim\text{mm}$) implica que el borde distal de la dosis no es perfectamente afilado. Clínicamente esto obliga a dejar márgenes de seguridad alrededor del tumor y limita la precisión con que se puede proteger el tejido sano inmediatamente detrás del tumor. La caracterización precisa del straggling es esencial para la planificación del tratamiento.

Conclusiones

En el Problema 1 se demostró que modelos de Machine Learning pueden resolver el problema inverso de inferir parámetros físicos a partir de señales ruidosas, siendo k más fácil de inferir que γ , y degradándose el desempeño al aumentar el ruido. En el Problema 2 se construyó un simulador Monte Carlo del transporte de protones que reproduce el pico de Bragg y su ensanchamiento por straggling, con rangos consistentes con los valores tabulados de NIST.